

國立清華大學動力機械工程學系

深度學習與應用

Deep Learning and Applications

Homework 3

授課教師：黃靖敬 助理教授

學生：潘佳成

中華民國 114 年 12 月 9 日

目錄


一、	Air Quality Analysis and LSTM Forecasting	3
	Task 1.....	3
	Task 2.....	5
	Task 3.....	6
二、	Lego Minifigure Generation.....	9
	Task 1.....	9
	Task 2.....	10
	Task 3.....	12

一、Air Quality Analysis and LSTM Forecasting

Task 1.




(圖一，correlation coefficient matrix)



(圖二，PM2.5 vs Temperature)

Task 2.




(圖三，input-output example)

Task 3.


我們使用 PM2.5、PM10、O3、NO2、溫度、相對濕度和風速成功訓練出一個 LSTM 模型，用以預測未來 24 小時 PM2.5 的值。從下圖四(learning curve)中可以發現 validation loss 雖然沒有完整收斂，但也沒發生過擬合的情況，代表模型訓練還算成功。

而從下圖五(Prediction result)來看，預測結果雖然無法精準跟隨實際 PM2.5 值，但也能大致預測出下一時段的走勢與動態，而下圖也顯示出預測準確以短期為佳，從 Test Sample Index 200 這項測試結果更可以明顯看出前六小時預測走勢與實際值大致相同，而 18~24 小時則較為不準，我認為因為 LSTM 是以短期資料作為訓練，所以針對短時間的預測會較為準確，而長時間則會受到太多變因干擾，導致無法準確預測。



(圖四，learning curve)

Task 3: Prediction Results (5 Examples)



(圖五， Prediction results)

Quantitative Metrics

	Value	Interpretation
MAE	3.6046	平均預測誤差約為 3。由於 PM2.5 的日變化通常在 10 ~ 20 範圍內，此誤差值表現良好。
RMSE	4.5971	略高於 MAE，表示模型在預測 PM2.5 尖峰或低谷時，仍有較大的單點誤差。
MAPE	29306005%	由於夏季 PM2.5 濃度在清晨可能接近零，推測可能是因為這樣導致分母極小，因此數值異常大。


Task 1.

Task 1: Preprocessed Lego Minifigures (64x64)



(圖六，sampled Minifigure images)

Task 2.



(圖七，Learning curves)



(圖八，original images and reconstructed outputs)


Task 2: Novel Generated Minifigures (from noise)



(圖九，novel samples)


Task 3.

針對測試集圖像在 VAE 潛在空間的分佈，我們執行了主成分分析並降維至 2D 進行可視化，雖然圖上數據點呈現連續的雲團狀且沒有明顯的離散分群，但這是因為 VAE 的目標是學會數據的連續分佈，並確保可以從空間中的任何一個點隨機採樣，解碼出來的結果都是一個有效且合理的樂高人偶，因此圖十(PCA)證明了模型成功組織了潛在空間。




(圖十，PCA)

從下圖十一(interpolation path)中 z_a (圖左側) 到 z_b (圖右側) 的轉換過程中，圖像的變化是漸進且連貫的，包括人偶的主體大小及顏色配件(帽子)的轉換以及姿勢等，中間的圖像沒有變成無效的噪點或雜訊，這證明了 VAE 成功地透過 KL divergence，確保潛在空間是連續的。因此，沿著空間中的線性插值也對應到圖像空間中的變化。




(圖十一，interpolation path)

下圖十二可以看出 β 與 reconstruction sharpness 之間的反向權衡。 $\beta = 0$ 的模型中影像細節最清晰銳利，因為他只優化像素級的準確度。隨著 β 值增加，模型將更多變異性壓縮到潛在空間，導致重建圖的清晰度逐漸下降，最終可以看到當 $\beta = 100$ 時，輸出相比原始圖像最為模糊。



(圖十二，reconstruction sharpness)

根據下圖十三，模型在生成多樣性上與 β 值呈現正相關。而 $\beta = 100$ 的模型呈現出最高的多樣性，因為 KL 懲罰迫使潛在空間緊密貼合 $N(0, I)$ ，使得從中採樣的 z 向量都能產生有效的輸出。而代價則是這些生成的圖像普遍較模糊且缺乏細節。相較之下， $\beta = 0$ 幾乎無法產生多樣且清晰的圖像， $\beta = 1$ 則在維持生成多樣性的同時，輸出了效果最佳的圖像。



(圖十三，generative diversity)